Data Cleaning, Feature Analysis e Feature Engineering no Dataset UCI Air Quality

João Abreu
Faculdade de Ciências Exatas e da Engenharia
Universidade da Madeira, Madeira, Portugal

***Resumo*—Este trabalho prepara o dataset *UCI Air Quality* para prever, hora a hora, a concentração de monóxido de carbono (CO). Primeiro, os dados foram limpos: os missing values foram tratados e os valores extremos limitados, usando apenas informação do conjunto de treino. Depois, criaram-se novas features que descrevem o ciclo diário e semanal e o efeito da temperatura e da humidade. Por fim, a seleção eliminou as variáveis irrelevantes e redundantes e reduziu 17 features a 11. Para avaliar o conjunto final, treinou-se uma regressão linear simples, que obteve um R^2 de 0.789 no conjunto de teste.**

I. Introdução

O presente relatório descreve a preparação do *dataset UCI Air Quality*, que reúne cerca de um ano de medições horárias de uma estação de qualidade do ar instalada numa cidade italiana, tendo como variável alvo a concentração de monóxido de carbono, $CO(GT)$. Para além do CO, o conjunto inclui as respostas de cinco sensores químicos, as concentrações de outros poluentes e variáveis meteorológicas como a temperatura e a humidade.

Para preparar estes dados, o trabalho seguiu uma metodologia dividida em três fases. Inicialmente, procedeu-se à limpeza e tratamento dos dados, onde se eliminaram as colunas e os registos sem informação útil, se preencheram as falhas de medição por interpolação ao longo do tempo e se mitigou o impacto dos *outliers* através do *clipping*, garantindo a integridade estatística da amostra sem quebrar a sequência temporal.

Posteriormente, a fase de *Feature Engineering* expandiu o potencial preditivo do *dataset* através da criação de 6 novos indicadores. Estas novas variáveis foram desenhadas para captar o ciclo diário e semanal do tráfego e o efeito da temperatura e da humidade no sensor de CO, relações que as variáveis originais, de forma isolada, não conseguiam representar.

Por fim, a *Feature Selection* eliminou as variáveis irrelevantes e redundantes, reduzindo o conjunto de 17 para 11 *features*. Também foram feitas análises de dimensionalidade, utilizando *Principal Component Analysis* (PCA) e *Linear Discriminant Analysis* (LDA), que permitiram identificar as principais direções de variação dos dados e avaliar a separação entre os diferentes níveis de CO.

II. Problem Formulation

A. Descrição do problema

Neste projeto é utilizado o *dataset* UCI Air Quality [1], que contém medições horárias de uma estação de qualidade do ar, incluindo o valor real do monóxido de carbono, $CO(GT)$, as respostas dos sensores químicos da estação, as concentrações de outros gases, a temperatura e a humidade. O objetivo é prever o $CO(GT)$ a partir das restantes variáveis.

No entanto, os dados não podem ser utilizados diretamente, uma vez que apresentam vários problemas. As falhas de medição surgem registadas com o valor -200, a variável NMHC(GT) tem mais de 90% dos valores em falta, existem picos de poluição muito afastados dos valores habituais e vários sensores medem, no fundo, a mesma informação. Se não forem tratados, estes problemas distorcem as estatísticas e dificultam a identificação das variáveis realmente relevantes. Por esse motivo, torna-se necessário limpar os dados, analisar a relação de cada variável com o CO e preparar um conjunto reduzido de *features* que melhor o expliquem.

B. Objetivos

O objetivo primordial deste projeto é transformar os dados originais num conjunto limpo e pronto a ser usado por um modelo de previsão do $CO(GT)$, garantindo que o conjunto de teste nunca influencia as decisões tomadas no treino (*data leakage*).

C. Objetivos Específicos

No âmbito técnico e exploratório, pretende-se:

- Compreender a estrutura e a importância das variáveis do *dataset*.
- Tratar as falhas de medição e os valores extremos sem quebrar a sequência temporal.
- Identificar padrões temporais e relações entre os sensores e o CO.
- Criar novas *features* que acrescentem informação às originais.
- Selecionar um número reduzido de *features* relevantes e não redundantes.
- Avaliar o efeito de cada etapa nos dados.

III. Data Analysis and Cleaning

A. Descrição do Dataset

O ficheiro `AirQualityUCI.csv` [1] contém medições horárias registadas entre 10 de março de 2004 e 4 de abril de 2005 [2], num total de 9471 linhas e 17 colunas. Abaixo apresenta-se a descrição das variáveis presentes no *dataset*.

- **Date** – Data da medição (DD/MM/AAAA).
- **Time** – Hora da medição (HH.MM.SS).

- **CO(GT)** – Concentração real de monóxido de carbono (mg/m^3), medida por um analisador de referência. É o *target*.
- **PT08.S1(CO)** – Resposta do sensor de óxido de estanho, sensível ao CO.
- **NMHC(GT)** – Concentração real de hidrocarbonetos não metânicos (μg/m^3).
- **C6H6(GT)** – Concentração real de benzeno (μg/m^3).
- **PT08.S2(NMHC)** – Resposta do sensor de titânia, sensível aos NMHC.
- **NOx(GT)** – Concentração real de óxidos de azoto (ppb).
- **PT08.S3(NOx)** – Resposta do sensor de óxido de tungsténio, sensível aos NO_x.
- **NO2(GT)** – Concentração real de dióxido de azoto (μg/m^3).
- **PT08.S4(NO2)** – Resposta do sensor de óxido de tungsténio, sensível ao NO_2.
- **PT08.S5(O3)** – Resposta do sensor de óxido de índio, sensível ao ozono.
- **T** – Temperatura do ar (°C).
- **RH** – Humidade relativa (%).
- **AH** – Humidade absoluta.
- **Unnamed: 15** e **Unnamed: 16** – Colunas vazias.

As variáveis `Date` e `Time` são temporais e as restantes 13 são numéricas.

B. Pré-processamento

O código está organizado nos mesmos módulos na biblioteca `nnlib.m`, que contém as funções, e no *script* `projeto.m`, que os executa por esta ordem:

- **Data Loader:** Responsável pela ingestão, isolamento do *target* e divisão do *dataset*.
- **Data Cleaning:** Focado no tratamento das falhas de medição e dos *outliers*.
- **Data Visualization:** Dedicado aos gráficos dos *missing values*, do efeito da limpeza, das distribuições e da relação com o *target* (Secção III-D).
- **Data Preprocessing:** Responsável pela normalização.
- **EDA:** Dedicado à tabela resumo e à PCA (Secção III-C).
- **Feature Analysis:** Responsável pelo *Feature Engineering* e pela *Feature Selection* (Secções IV e V).

1) Data Loader: Esta etapa executa a carga inicial do *dataset*, isola a variável *target* e divide os dados nos conjuntos de treino e de teste:

- **Carga do dataset:** O ficheiro é lido tal como está: deteta-se o separador (ponto e vírgula), converte-se a vírgula decimal em ponto e separam-se as colunas numéricas das colunas de texto. São também descartadas as duas colunas `Unnamed` e as 114 linhas vazias do fim do ficheiro, que resultam do formato do CSV, ficando 9357 observações e 15 variáveis.
- **Isolamento do target:** A variável $CO(GT)$ é definida como *target* logo no início do fluxo. A partir daqui, é tratada à parte das *features*: nunca é preenchida, não é normalizada nem sujeita a *clipping*.
- **Divisão do dataset:** Como se trata de uma série temporal, a divisão é cronológica e não aleatória. As primeiras 70% das observações (6550) formam o treino e as restantes 30% (2807) o teste. Esta separação precoce é uma medida para mitigar o risco de *data leakage*.

2) Data Cleaning: Este módulo dedica-se à limpeza do *dataset*, eliminando as inconsistências que poderiam comprometer a aprendizagem. Em primeiro lugar, são removidos os dados sem informação útil, pela seguinte ordem, sendo os passos 2 a 4 repetidos no teste:

1) **Duplicados:** Não foram encontradas linhas repetidas no treino.
2) **Código de falha:** Os valores -200, que no *dataset* indicam uma medição em falta, passam a `NaN` (11354 valores no treino).
3) **NMHC(GT):** A variável foi removida, uma vez que tem 90.2% de *missing values*. Preenchê-la obrigaria a inventar nove em cada dez valores.
4) **Remoção do target em falta:** As linhas sem $CO(GT)$ foram removidas (1483 no treino e 200 no teste). O *target* nunca é preenchido, para que o modelo não aprenda valores artificiais.

Depois de removidos os dados sem informação útil, os valores que restam são tratados no treino e no teste, preenchendo as falhas de medição e limitando os *outliers*:

1) **Interpolação linear:** Utilizada para preencher as falhas restantes nas *features*. Os valores em falta são preenchidos pela ordem do tempo, com a reta entre o valor anterior e o seguinte. Nos extremos da coluna, onde só existe um vizinho, copia-se o valor mais próximo. Foram preenchidos 1692 valores no treino e 2107 no teste. Esta opção aproveita o facto de as medições serem horárias e variarem de forma contínua, o que torna o valor entre duas horas vizinhas uma melhor estimativa do que a média global.
2) **Clipping:** Utilizado para limitar os *outliers*. Os limites $[Q_1 - 3\,\mathrm{IQR},\ Q_3 + 3\,\mathrm{IQR}]$ são calculados no treino e cada valor fora deles passa a ser o próprio limite, mantendo-se a linha. No teste são aplicados os mesmos limites do treino. Foram alterados 130 valores no treino (95 em NOx(GT), 17 em C6H6(GT), 17 em PT08.S3(NOx) e 1 em NO2(GT)). O *target* não é limitado.

```
% --- treino ---
[data_train, nMissing] = L.handleMissingValues(data_train,
    isNum_tr);   % interpolacao linear
% IQR com k=3; o target nao e alterado; os limites ficam
    guardados
[data_train, nOut, lim_lower, lim_upper] = L.removeOutliers
    (data_train, isNum_tr, 3, header_tr, target);
fprintf('Valores preenchidos por interpolacao: %d\n', sum(
    nMissing));
% --- teste: interpolacao e clipping com os limites do
    treino ---
[data_test, nMissingT] = L.handleMissingValues(data_test,
    isNum_te);
data_test = L.clipToLimits(data_test, isNum_te, lim_lower,
    lim_upper);
fprintf('Teste | Valores preenchidos por interpolacao: %d\n
    ', sum(nMissingT));
```

Listing 1. Interpolação e clipping no treino e no teste (`projeto.m`).

3) Data Preprocessing: A etapa final do pré-processamento prepara os dados para os algoritmos através do *StandardScaler* ($\mu = 0$, $\sigma = 1$), com a média e o desvio-padrão calculados no treino e aplicados também ao teste. As 11 variáveis originais são normalizadas neste módulo. É guardada uma cópia em unidades reais, utilizada na tabela resumo da EDA e na criação das novas *features*, que são normalizadas da mesma forma logo após serem criadas.

Não foi utilizado nenhum método de codificação categórica, uma vez que não existem variáveis binárias nem categóricas entre as *features*.

C. Análise Exploratória de Dados (EDA)

Nesta fase foi feito o diagnóstico estatístico das variáveis, avaliando a sua distribuição e a eficácia da limpeza.

1) Análise Descritiva e Estabilidade de Amostragem: Após a limpeza, o conjunto de treino ficou com 5067 registos e o conjunto de teste com 2607. Como a divisão é cronológica, o treino e o teste correspondem a períodos diferentes do ano e não têm, necessariamente, as mesmas distribuições. Para o verificar, compararam-se as médias dos dois conjuntos depois da normalização com os parâmetros do treino: no treino a média de cada variável é zero, pelo que, se os dois conjuntos fossem iguais, a média no teste também ficaria próxima de zero. Tal não acontece, por exemplo, no PT08.S1(CO) ($+0.11$) e no C6H6(GT) (-0.23). Esta diferença é esperada, uma vez que o teste cobre o inverno e o início da primavera e os sensores apresentam deriva ao longo do tempo [2], o que torna o teste mais exigente do que uma divisão aleatória.

2) Interpretação dos Indicadores Estatísticos: A Tabela I apresenta os *missing values* antes da limpeza e a Tabela II as estatísticas do treino limpo.

Tabela I
MISSING VALUES (CÓDIGO -200) POR VARIÁVEL, NO *dataset* COMPLETO ANTES DA LIMPEZA

Variável	% em falta
NMHC(GT)	90.2
CO(GT) (target)	18.0
NOx(GT), NO2(GT)	17.5
Sensores PT08, C6H6(GT), T, RH, AH	3.9

Com base nos dados extraídos, destacam-se as seguintes observações sobre o estado do *dataset*:

1) **Falhas:** Os 3.9% comuns a todos os sensores e às variáveis meteorológicas correspondem a horas em que a estação inteira falhou, uma vez que as falhas ocorrem nas mesmas linhas. As falhas do CO, dos NO_x e do NO_2 vêm dos analisadores de referência e não coincidem com as dos sensores.
2) **Gamas de valores:** Os sensores PT08 variam entre algumas centenas e cerca de 2800, o CO entre 0.1 e 11.9 mg/m^3, o NOx entre 2 e 1389 ppb (antes da limpeza), a temperatura entre 1 e 45 °C e a humidade relativa entre 9 e 89%. Estas escalas tão diferentes justificam a normalização.

Tabela II
TABELA RESUMO (TREINO LIMPO, UNIDADES ORIGINAIS)

Variável	Média	Desvio	Assim.	r	ρ
C6H6(GT)	10.9	7.6	1.23	0.946	0.940
PT08.S2(NMHC)	971	265	0.53	0.927	0.939
PT08.S1(CO)	1105	223	0.77	0.895	0.898
PT08.S5(O3)	1019	382	0.63	0.868	0.866
NOx(GT)	202	178	1.68	0.783	0.824
NO2(GT)	98	41	0.64	0.775	0.844
PT08.S4(NO2)	1581	295	0.41	0.753	0.734
PT08.S3(NOx)	857	253	0.94	-0.721	-0.818
RH	47.5	17.4	0.04	0.065	-0.008
AH	1.15	0.35	0.26	0.022	0.016
T	21.5	7.8	0.34	-0.026	0.029
CO(GT) (target)	2.14	1.44	1.41	–	–

r = Pearson e ρ = Spearman com o CO(GT).

3) **Distribuição do target:** O $CO(GT)$ tem média de 2.14 mg/m^3, mediana de 1.80 e assimetria de 1.41. A maior parte das horas tem pouco CO, existindo uma cauda longa de picos.
4) **Relação com o target:** Os sensores e as concentrações relacionam-se fortemente com o CO ($|r|$ entre 0.72 e 0.95), e os valores de Pearson e Spearman são próximos, o que indica relações aproximadamente lineares. O PT08.S3(NOx) é a única variável com sinal negativo, enquanto T, RH e AH não se relacionam com o CO ($|r| < 0.07$).
5) **Redundância:** O C6H6(GT) e o PT08.S2(NMHC) têm $|r| = 0.985$, e o PT08.S5(O3) e o PT08.S1(CO) correlacionam-se a cerca de 0.90 com ambos. Este bloco de variáveis mede, no fundo, a mesma coisa: a poluição do tráfego.

D. Data Visualization

Os gráficos desta secção foram produzidos sobre o conjunto de treino, com exceção do gráfico dos *missing values*, que usa o *dataset* completo antes da divisão.

1) Missing Values: A leitura do gráfico da Fig. 1 permite identificar a percentagem de *missing values* por variável, antes da limpeza:

- **NMHC(GT):** Destaca-se com 90.2% de falhas, muito acima de todas as outras variáveis.
- **Target e NO_x/NO_2:** Apresentam cerca de 18% de falhas cada.
- **Sensores e variáveis meteorológicas:** Têm exatamente 3.9% de falhas, o que confirma que correspondem a falhas da estação inteira.

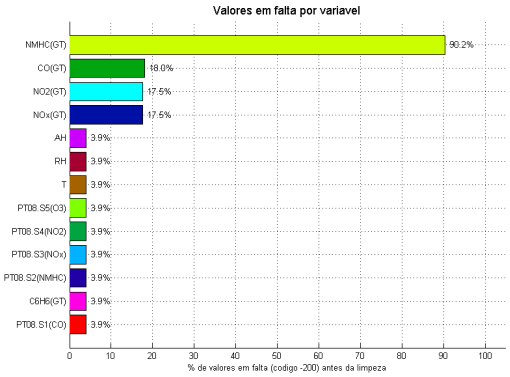


Figura 1. Percentagem de missing values por variável, no dataset completo.

2) Antes e Depois da Limpeza: A Fig. 12 (Apêndice A) e a Tabela III permitem comparar algumas variáveis antes e depois da limpeza:

- **Antes:** Os histogramas do CO, do NOx e do C6H6 apresentam uma barra isolada em -200, longe dos valores reais.
- **Depois:** Essa barra desaparece. A média e o desvio-padrão do CO mantêm-se e os do PT08.S1(CO) variam menos de 2%, o que demonstra que a limpeza não altera a forma real dos dados.
- **NOx(GT):** O valor máximo passa de 1389 para 824 e a assimetria de 2.22 para 1.68. Os valores sujeitos a *clipping* acumulam-se no limite superior, onde surge uma pequena barra.

Tabela III
ANTES E DEPOIS DA LIMPEZA

Variável	Média	Desvio	Máximo	Assimetria
CO(GT)	2.14 → 2.14	1.44 → 1.44	11.9 → 11.9	1.41 → 1.41
NOx(GT)	201 → 202	191 → 178	1389 → 824	2.22 → 1.68
C6H6(GT)	10.8 → 10.9	7.65 → 7.55	63.7 → 43.8	1.34 → 1.23
PT08.S1(CO)	1099 → 1105	220 → 223	2040 → 2040	0.78 → 0.77

3) Feature Distribution: As Figs. 10 e 11 (Apêndice A) mostram a distribuição de cada variável original e do *target* no treino limpo. Para cada variável é apresentado um histograma, que indica quantas horas têm cada valor, uma curva normal de referência, que mostra a forma que a variável teria se fosse simétrica, e um *boxplot*, onde são contados os *outliers* pela regra $1.5 \times$ IQR. A assimetria resume a forma de cada distribuição: um valor próximo de 0 indica uma variável simétrica, e um valor acima de 1 indica que a maioria das horas tem valores baixos e que existem alguns valores muito altos, que formam uma cauda longa à direita. A análise das distribuições revela o seguinte:

- **Assimetria positiva forte:** O *target* (1.41), o NOx(GT) (1.68) e o C6H6(GT) (1.23) têm a maior parte das horas concentrada em valores baixos e uma cauda longa à direita. Esta cauda corresponde aos picos de poluição das horas de ponta. No NOx(GT) surge ainda uma pequena barra isolada no valor máximo (824 ppb), que corresponde aos valores limitados pelo *clipping*.
- **Sensores PT08:** Têm assimetria moderada, entre 0.41 no PT08.S4(NO2) e 0.94 no PT08.S3(NOx), e histogramas em forma de sino, próximos da curva normal.
- **Variáveis meteorológicas:** A T (0.34), a RH (0.04) e a AH (0.26) são praticamente simétricas e quase não têm *outliers* (7 na T, 0 na RH e 2 na AH), o que indica que variam de forma regular ao longo do ano.
- **Outliers pela regra 1.5:** As variáveis com mais *outliers* são o NOx(GT) (330), o CO(GT) (170), o PT08.S3(NOx) (141) e o C6H6(GT) (136), precisamente as que têm caudas mais longas. Como estes valores correspondem a picos reais de poluição e não a erros de medição, foram mantidos, e apenas os valores acima de $3 \times$ IQR foram sujeitos a *clipping*.

4) Features vs Target: A leitura do gráfico da Fig. 13 (Apêndice A), que apresenta as seis variáveis mais correlacionadas com o CO e a respetiva reta de mínimos quadrados, permite retirar as seguintes conclusões:

- **Relação linear:** É clara no C6H6(GT) ($r = 0.95$), no PT08.S2(NMHC) (0.93), no PT08.S1(CO) (0.89) e no PT08.S5(O3) (0.87).
- **Maior dispersão para CO alto:** A nuvem de pontos abre à medida que o CO sobe, sendo nessa zona que o modelo terá mais erros.
- **NOx e NO_2:** Acompanham o CO ($r \approx 0.78$), mas com mais dispersão, uma vez que também têm outras fontes.

5) Correlation Heatmap: A Fig. 9 (Apêndice A) mostra a correlação entre as 11 *features* finais e o CO. Cores fortes indicam uma relação forte, positiva ou negativa, e cores claras indicam pouca relação. A leitura do gráfico permite retirar as seguintes conclusões:

- **Relação com o CO:** As variáveis mais ligadas ao CO são a fusão C6H6+PT08.S2+PT08.S5 ($r = 0.94$) e o PT08.S1(CO) (0.89), seguidas do NOx(GT) (0.78), do PT08.S4(NO2) (0.75) e do PT08.S3(NOx) (-0.72). As novas *features* têm uma relação mais fraca: 0.50 na interação com a humidade, 0.39 na interação com a temperatura, -0.35 no Hour_sin e até 0.20 no dia da semana.
- **Redundância que ainda existe:** Algumas *features* continuam muito ligadas entre si: o PT08.S1(CO) e a fusão ($r = 0.92$), e o PT08.S3(NOx) e o PT08.S4(NO2) ($r = -0.82$ e 0.82 com outras variáveis do bloco).
- **Ciclos independentes:** O seno e o cosseno da hora e do dia da semana quase não se relacionam entre si ($|r| \leq 0.02$) nem com os sensores ($|r| \leq 0.42$), o que confirma que trazem informação diferente.

6) Feature Importance: A Fig. 2 apresenta a *permutation importance* das 17 *features*, com um modelo linear e antes de qualquer remoção. A leitura do gráfico permite retirar as seguintes conclusões:

- **Valores inflacionados:** O C6H6(GT) chega a 2.20 e o PT08.S2(NMHC) a 0.84, valores superiores ao próprio R^2 (0.939). Como estas duas variáveis têm $|r| = 0.985$, o modelo linear atribui-lhes pesos grandes e de sinais opostos, que se compensam, pelo que baralhar uma delas desfaz essa compensação.
- **RH com 0.024:** Pela mesma razão, a humidade surge como importante apenas por compensar a interação sensor×humidade (0.054), com a qual está ligada; sozinha, não se relaciona com o CO ($|r| = 0.07$).
- **Conclusão:** Com variáveis colineares, a importância de um modelo linear não é fiável. Por esse motivo, a seleção remove primeiro as irrelevantes e funde os grupos colineares, e só depois mede a importância.

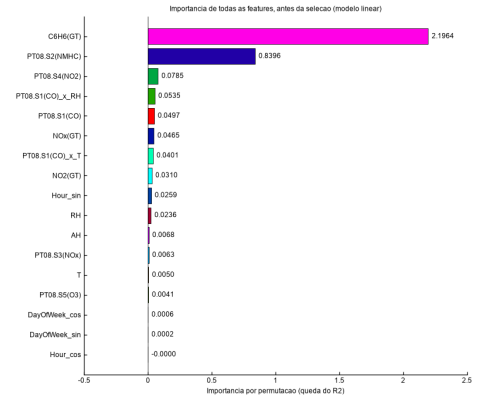


Figura 2. Permutation importance de todas as features, antes da seleção (modelo linear).

7) PCA: No PCA verificamos se as componentes separam os níveis de poluição, o *target* foi dividido em três grupos do mesmo tamanho , que servem apenas para colorir os pontos, uma vez que a PCA calcula os eixos sem conhecer o CO:

- **Baixo, a azul** (≤ 1.3 mg/m^3, CO médio de 0.83): Metade das horas são de madrugada e 42% são de fim de semana.
- **Médio, a laranja** (1.3 a 2.4 mg/m^3, CO médio de 1.86): Corresponde sobretudo a horas do meio do dia e do fim da noite.
- **Alto, a vermelho** (> 2.4 mg/m^3, CO médio de 3.77): 55% são horas de ponta (8h e 18h a 20h) e apenas 14% são de fim de semana.

A Fig. 3 mostra, à esquerda, os pontos projetados nos dois primeiros eixos, com um círculo no centro de cada grupo e uma elipse que delimita a sua dispersão, e, à direita, a distribuição de cada grupo ao longo da PC1 e da PC2. A leitura do gráfico permite retirar as seguintes conclusões:

- **PC1 (58.1%) representa a poluição:** Os sensores e as concentrações têm todos um peso semelhante. Os três grupos ficam ordenados ao longo deste eixo: o grupo alto (vermelho) à esquerda, com centro em -2.8, o médio (laranja) ao centro, em 0.3, e o baixo (azul) à direita, em 2.4. No painel da distribuição da PC1, as três curvas aparecem, por isso, lado a lado.
- **PC2 (18.1%) representa o tempo meteorológico:** Opõe a temperatura (-0.69) à humidade ($+0.51$). No painel da distribuição da PC2, as curvas azul, laranja e vermelha praticamente se sobrepõem, o que indica que o tempo meteorológico não distingue os níveis de CO.
- **Redundância:** Os sensores apontam todos na mesma direção, pelo que o gráfico desenha uma só seta para representar o bloco. Este é o grupo que a seleção vai fundir.
- **Separação:** 82.1% dos pontos ficam mais perto do centro do seu grupo. Os erros ocorrem entre grupos vizinhos, enquanto o baixo e o alto quase nunca se confundem ($\leq 0.6\%$).

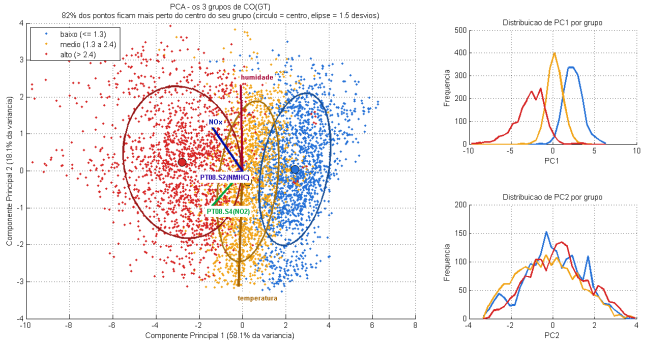


Figura 3. PCA das 11 variáveis originais, com os 3 grupos de CO.

8) LDA: A LDA (*Linear Discriminant Analysis*) utiliza os mesmos três grupos de CO da Secção III-D7, mas, ao contrário da PCA, usa-os para escolher os eixos, procurando a combinação das variáveis que mais afasta os centros dos grupos. Foi aplicada às 5 variáveis contínuas do conjunto final: PT08.S1(CO), NOx(GT), PT08.S3(NOx), PT08.S4(NO2) e a fusão C6H6+PT08.S2+PT08.S5. A leitura da Fig. 4 permite retirar as seguintes conclusões:

- **Separação:** 81.1% dos pontos ficam mais perto do centro do seu grupo, praticamente o mesmo que na PCA (82.1%).
- **Erros por grupo:** Ficam no grupo certo 79.9% dos baixos, 84.9% dos médios e 78.7% dos altos. Os erros ocorrem entre grupos vizinhos: 20.1% dos baixos e 20.6% dos altos caem no médio, e o baixo e o alto quase nunca se confundem ($\leq 0.7\%$).

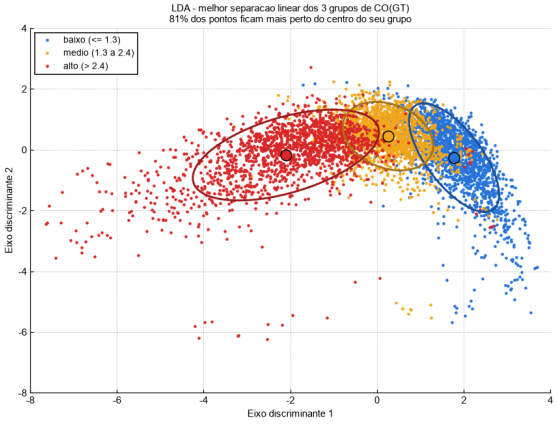


Figura 4. LDA das 5 variáveis contínuas finais, com os 3 grupos de CO.

9) Padrões Temporais: A análise do CO médio por hora (Fig. 6) e por dia da semana permite identificar dois ciclos:

- **Ciclo diário:** Existem dois picos, às 8h e às 19h, ligados ao tráfego, e um mínimo entre as 3h e as 5h.
- **Ciclo semanal:** De terça a sexta-feira o CO médio fica perto de 2.45 mg/m^3 e à segunda-feira é de 2.0, descendo para 1.8 ao sábado e 1.33 ao domingo.

IV. Feature Engineering

A fase de *Feature Engineering* é apresentada antes da *Feature Selection*, uma vez que a seleção é feita sobre o conjunto já enriquecido. Foram criados dois grupos de *features*, calculadas linha a linha a partir de informação já existente, pelo que não há *data leakage* entre treino e teste.

A. Hora e Dia da Semana como Ciclos

A hora (0 a 23) e o dia da semana (0 = segunda-feira a 6 = domingo) são variáveis cíclicas: as 23h ficam ao lado das 0h e o domingo ao lado da segunda-feira, mas como números ficam em extremos opostos. Para resolver este problema, cada uma foi representada por um par seno/cosseno, que coloca os valores num círculo:

$$\text{Hour_sin} = \sin\left(\frac{2\pi h}{24}\right), \qquad \text{Hour_cos} = \cos\left(\frac{2\pi h}{24}\right), \quad (1)$$

e da mesma forma `DayOfWeek_sin`/`DayOfWeek_cos` com período 7. Como o seno sozinho dá o mesmo valor a duas horas diferentes, o par é sempre mantido ou removido em conjunto.

B. Interações do Sensor de CO com a Temperatura e a Humidade

A resposta dos sensores de óxidos metálicos varia com a temperatura e com a humidade. Para que um modelo linear consiga representar este efeito, foram criadas duas novas *features*, PT08.S1(CO)×T e PT08.S1(CO)×RH, que correspondem ao produto do sensor PT08.S1(CO) pela temperatura e pela humidade relativa. Com estes termos, o peso do sensor na previsão passa a depender da temperatura ou da humidade.

```
% seno/cosseno da hora e do dia da semana (0 = segunda)
[header, data, isNum] = appendColumn(header, data, isNum, '
    Hour_sin', sin(2*pi*hour/24));
[header, data, isNum] = appendColumn(header, data, isNum, '
    Hour_cos', cos(2*pi*hour/24));
[header, data, isNum] = appendColumn(header, data, isNum, '
    DayOfWeek_sin', sin(2*pi*dow/7));
[header, data, isNum] = appendColumn(header, data, isNum, '
    DayOfWeek_cos', cos(2*pi*dow/7));
% interacoes: o sensor (1a coluna) com cada uma das outras
for j = 2:numel(cols)
    [header, data, isNum] = appendColumn(header, data,
        isNum, [cols{1} '_x_' cols{j}], x .* y);
end
```

Listing 2. Criação das features (excerto simplificado de `nnlib.m`).

C. Features Avaliadas e Não Incluídas

Durante o trabalho foram testadas outras *features* que não chegaram ao conjunto final e que, por isso, deixaram de ser criadas:

- **Month e IS_RUSH_HOUR:** Não passavam a seleção.
- **IS_WEEKEND:** Foi substituída pelo seno/cosseno do dia da semana, que descreve o ciclo semanal completo.
- **Seno/cosseno do dia do ano:** Piorava o teste cronológico (R^2 de 0.793 para 0.767), uma vez que o teste tem meses de inverno que o treino não cobre por inteiro.
- **Razão NO_2/NO_x:** Foi removida por baixa importância.
- **Interação T×RH:** Revelou-se sempre irrelevante ($|r| \approx 0.05$ com o CO).
- **Sigmoide da soma do sensor com T e com RH:** Era quase igual ao produto e não acrescentava informação, uma vez que, na seleção, cada sigmoide se fundia com o produto correspondente.

D. Medição do Ganho

Para verificar se as novas *features* trazem informação útil, foram comparadas duas regressões lineares de mínimos quadrados, que diferem apenas nas entradas: uma com as 11 variáveis originais e outra com as originais e as novas *features*. Os pesos são calculados em 70% do treino, escolhidos ao acaso com semente fixa, e o R^2 é medido nos restantes 30%, que o modelo não viu.

E. Visualização das Novas Features

1) Efeito do Feature Engineering: A Fig. 5 apresenta, à esquerda, o R^2 à medida que se juntam as novas *features* e, à direita, o CO médio de cada hora do dia, real e previsto pelos dois modelos. A leitura do gráfico permite retirar as seguintes conclusões:

- **R^2 de validação:** Passa de 0.9317 com as 11 originais para 0.9385 com o seno/cosseno da hora e do dia, e para 0.9393 com as interações. O RMSE desce de 0.368 para 0.347 mg/m^3.
- **Localização da melhoria:** O modelo com as novas *features* fica mais perto do CO real nas subidas da manhã (5h–8h) e no pico do fim da tarde (18h–21h). No meio do dia (9h–17h) afasta-se ligeiramente, uma vez que uma só onda por dia não consegue descer ao meio-dia e voltar a subir.

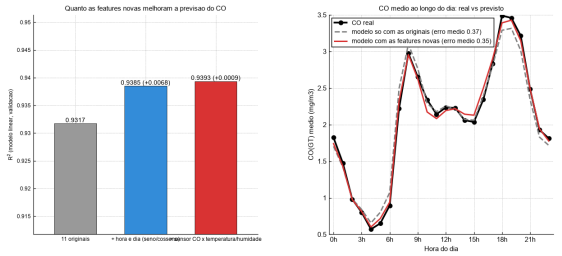


Figura 5. R^2 das novas features e CO médio por hora do dia, real e previsto.

2) Hora do Dia como Ciclo: A leitura do gráfico da Fig. 6 permite comparar o CO médio de cada hora com a curva que o seno/cosseno consegue reproduzir:

- **Uma onda por dia:** Explica $R^2 = 0.16$ do CO, captando a ideia geral (pouco CO de noite e muito ao fim da tarde), mas não os dois picos separados.
- **Duas ondas por dia:** Com um período de 12h, chega a $R^2 = 0.28$, uma vez que passa a captar os picos das 8h e das 19h.
- **Dia da semana:** Uma onda de seno/cosseno explica apenas $R^2 = 0.06$ do CO, o que confirma que o dia da semana acrescenta pouco.

Estes valores de R^2 são baixos porque a hora, sozinha, não indica a quantidade de CO: às 8h pode haver 1 ou 7 mg/m^3. A hora indica o momento do dia, e são os sensores que dão o valor.

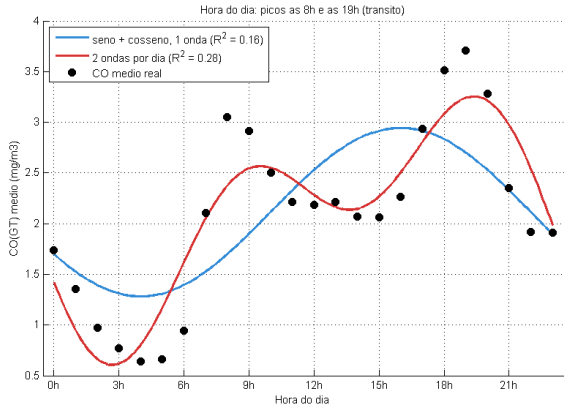


Figura 6. CO médio por hora do dia, com o ajuste de seno/cosseno (1 e 2 ondas por dia).

3) Ganho de Cada Nova Feature: A Fig. 7 apresenta o aumento do R^2 ao juntar cada nova *feature* às 11 originais (R^2 base $= 0.9317$). A cinzento encontra-se a mesma informação representada como número, para comparação:

- **Hora em seno/cosseno:** $+0.0063$, contra $+0.0024$ da hora em número, pelo que o *cyclical encoding* vale mais do dobro.
- **Dia da semana:** $+0.0003$ em seno/cosseno e $+0.0002$ em número, uma vez que a diferença entre dias já está quase toda contida nos sensores.
- **Interações:** O sensor×humidade acrescenta $+0.0027$, enquanto o sensor×temperatura não acrescenta nada (-0.0001), o que está de acordo com o efeito do sensor ser igual a qualquer temperatura.

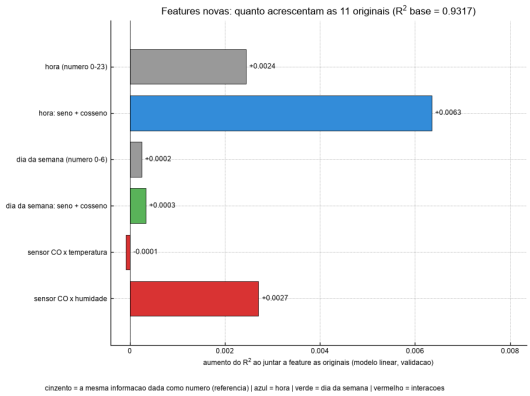


Figura 7. Ganho de R^2 de cada nova feature sobre as 11 originais.

4) Interações: Para confirmar o efeito das interações, mediu-se o aumento do CO por cada +100 no sensor, separando as horas em três grupos de temperatura e de humidade:

- **Temperatura:** O CO sobe 0.59, 0.57 e 0.58 mg/m^3 com temperatura baixa, média e alta, pelo que o efeito do sensor não depende da temperatura.
- **Humidade:** O mesmo aumento dá 0.52, 0.54 e 0.66 mg/m^3. Com humidade alta, o sensor tem mais peso, o que explica o maior ganho da interação com a humidade.
- **R^2:** Passa de 0.9317 sem interações para 0.9336 com elas.

V. Feature Selection

A. Critérios

A seleção é aplicada às 17 *features* do treino normalizado (11 originais, 4 cíclicas e 2 interações), em quatro passos:

1) **Irrelevantes:** É removida a *feature* com $|\text{Pearson}|$ e $|\text{Spearman}| < 0.15$ **e** *mutual information* < 0.1 com o *target*. A *mutual information* deteta relações não lineares que as correlações não identificam.
2) **Fusão de grupos colineares:** As *features* ligadas por $|r| > 0.9$ formam um grupo, que é substituído por uma única *feature*: a 1.ª componente principal do grupo. Desta forma, a informação comum é preservada, o que não aconteceria se se removessem membros do grupo.
3) **Permutation importance:** Com um modelo linear, mede-se quanto desce o R^2 de validação quando os valores de cada *feature* são baralhados, sendo removidas as que fazem descer menos de 0.005.

Nos passos 1 e 4, cada par seno/cosseno conta como um só grupo. A média, o desvio e os pesos de cada grupo fundido são guardados e aplicados ao teste.

```
ciclos = {{'Hour_sin','Hour_cos'}, {'DayOfWeek_sin','
    DayOfWeek_cos'}};
obrigatorias = {'DayOfWeek_sin', 'DayOfWeek_cos'};
[header_tr, data_train, isNum_tr, selection] = L.
    selectFeatures(header_tr, data_train, isNum_tr, target,
     0.15, 0.1, 0.999, 0.9, ciclos, obrigatorias);
[header_tr, data_train, isNum_tr, removed] = L.
    removeUnimportantFeatures(header_tr, data_train,
    isNum_tr, target, 0.005, ciclos, obrigatorias);
% no teste: a mesma receita, com os pesos do treino
[header_te, data_test, isNum_te] = L.applySelection(
    header_te, data_test, isNum_te, selection);
```

Listing 3. Seleção com pares inseparáveis e features obrigatórias (`projeto.m`).

B. Subconjunto Final

As 11 *features* finais são PT08.S1(CO), NOx(GT), PT08.S3(NOx), PT08.S4(NO2), Hour_sin, Hour_cos, DayOfWeek_sin, DayOfWeek_cos, PT08.S1(CO)×T, PT08.S1(CO)×RH e a fusão C6H6+PT08.S2+PT08.S5. Mantêm-se os sensores e as concentrações com mais informação sobre o CO, o ciclo diário e semanal e as duas interações, enquanto o bloco redundante de três variáveis passa a ser uma só. A remoção do NO2(GT) quase não altera a validação, uma vez que a sua informação já está contida no NOx(GT) e no PT08.S4(NO2).

C. Visualização da Seleção

1) Feature Importance:

a) Depois da Seleção: A Fig. 8 apresenta a importância recalculada com as 11 *features* finais. Cada valor indica quanto desce o R^2 de validação quando os valores dessa *feature* são baralhados, pelo que, quanto maior a descida, mais o modelo depende dela:

- **Mais importante:** A fusão C6H6+PT08.S2+PT08.S5, cuja permutação faz o R^2 cair 0.42, uma vez que concentra a informação do bloco de sensores de poluição.
- **Importância intermédia:** O NOx(GT) e o PT08.S4(NO2) (0.19), o PT08.S1(CO) (0.08) e a interação sensor×temperatura (0.06), que acrescentam informação que a fusão não contém.
- **Importância baixa:** O Hour_sin e o PT08.S3(NOx) (0.04) e a interação sensor×humidade (0.02).

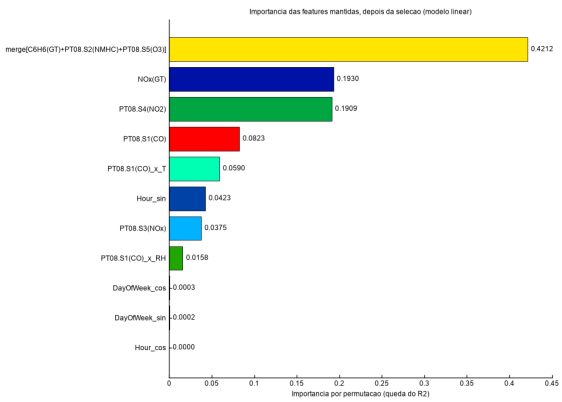


Figura 8. Permutation importance das 11 features finais (modelo linear).

VI. Resultados

A Tabela IV resume os principais resultados de cada etapa do trabalho.

Tabela IV
Resumo dos resultados por etapa

Etapa	Resultado
Importação	9357 observações, 15 variáveis; 18% do target em falta
Limpeza	treino 6550 → 5067, teste 2807 → 2607; 0 missing values; 130 valores com clipping (0.2% das células)
EDA / PCA	PC1 = poluição (58.1%), PC2 = tempo (18.1%); 82.1% dos pontos no grupo de CO certo
Feature Engineering	6 novas features; R^2 de validação 0.9317 → 0.9393; RMSE 0.368 → 0.347 mg/m^3
Feature Selection	T, RH e AH removidas; C6H6, PT08.S2 e PT08.S5 fundidas; NO2(GT) removida; 17 → 11 features
Modelo de verificação	$R^2 = 0.789$ e RMSE $= 0.681$ mg/m^3 no teste cronológico

Na limpeza, a comparação antes e depois (Tabela III e Fig. 12) mostra que a remoção do código -200 e o *clipping* eliminaram os valores impossíveis sem alterar a forma real dos dados: a média e o desvio-padrão do CO mantiveram-se e apenas 0.2% das células foram modificadas. No final, nem o treino nem o teste têm *missing values*.

A análise exploratória mostrou que os sensores e as concentrações estão fortemente relacionados com o CO, de forma aproximadamente linear (Tabela II e Fig. 13), enquanto a temperatura e a humidade não se relacionam diretamente com ele. O PCA (Fig. 3) confirmou esta divisão, separando os níveis de CO ao longo do eixo da poluição e não ao longo do eixo do tempo meteorológico.

As novas *features* aumentaram o R^2 de validação de 0.9317 para 0.9393 (Fig. 5), sendo o seno/cosseno da hora a que mais contribuiu (Fig. 7). A seleção reduziu depois o conjunto de 17 para 11 *features*, com uma perda de R^2 de validação inferior a 0.001 na última remoção, e eliminou a colinearidade que tornava instável a importância das variáveis (Figs. 2 e 8).

Por fim, a regressão linear treinada com todo o treino e as 11 *features* finais obteve $R^2 = 0.789$ e RMSE $= 0.681$ mg/m^3 no teste. As estruturas finais do treino e do teste coincidem, com 5067 e 2607 observações, as mesmas 11 *features* e o CO, pelo que o conjunto está pronto a ser utilizado nas fases seguintes.

VII. Discussão

De forma geral, as técnicas aplicadas mostraram-se eficazes na preparação dos dados. A limpeza permitiu tratar as falhas de medição e os valores extremos sem introduzir dados artificiais e sem quebrar a sequência temporal, alterando apenas uma pequena parte dos valores. A análise exploratória, em particular a PCA, revelou que a informação sobre o CO está concentrada nas variáveis de poluição e que as variáveis meteorológicas não a acrescentam diretamente, o que orientou as decisões da seleção. O *Feature Engineering* acrescentou informação útil, sobretudo através da representação cíclica da hora, e a seleção reduziu o conjunto a 11 *features*. A diferença entre o R^2 de validação e o do teste mostra ainda que, numa série temporal, uma avaliação feita no período seguinte é mais exigente e mais realista do que uma avaliação com horas escolhidas ao acaso.

Ao longo do trabalho surgiram alguns desafios. A divisão cronológica obrigou a calcular todos os parâmetros apenas no treino e a aplicá-los depois ao teste, para evitar *data leakage*. Além disso, a versão do MATLAB utilizada não dispõe de *toolboxes* estatísticas, pelo que vários métodos tiveram de ser implementados de raiz, e algumas *features* testadas acabaram por não trazer informação e foram abandonadas.

Como melhorias futuras, seria possível acrescentar uma segunda onda diária à representação da hora, para captar melhor os dois picos de tráfego, e validar as decisões por blocos temporais, em vez de uma divisão aleatória dentro do treino.

VIII. Conclusão

O presente trabalho permitiu estabelecer uma base sólida para o desenvolvimento de um modelo de previsão do monóxido de carbono, cumprindo os objetivos definidos para esta primeira fase. Ao longo deste relatório, foi possível transformar um conjunto de dados com 18% do *target* em falta, um código de erro e variáveis muito redundantes num *dataset* limpo de 11 *features*, preparado sem *data leakage* entre treino e teste.

As etapas de limpeza e de análise exploratória revelaram-se fundamentais para compreender o problema. A limpeza removeu as horas sem *target* e uma variável sem dados úteis, alterando apenas 0.2% dos valores, e a PCA mostrou que só a direção da poluição está ligada ao CO, o que justificou a fusão dos sensores e a remoção das variáveis meteorológicas. Adicionalmente, o *cyclical encoding* da hora foi a nova *feature* mais útil, e as interações mostraram que o efeito do sensor de CO depende da humidade.

Em trabalhos futuros de modelação preditiva, as *features* criadas poderão ser utilizadas diretamente como entradas do modelo, uma vez que já se encontram normalizadas e com os parâmetros do treino guardados para dados novos. A representação cíclica da hora e do dia da semana permite ao modelo distinguir os períodos de maior e menor tráfego, e as interações permitem ajustar a leitura do sensor de CO às condições de temperatura e humidade. Num modelo capaz de aprender relações não lineares, como uma rede neuronal, será ainda possível comparar o desempenho com e sem estas *features*, para avaliar se continuam a ser necessárias. Nessa comparação, o R^2 de 0.789 obtido pelo modelo linear no teste servirá de valor de referência.

Apêndice A
Figuras Adicionais

Este apêndice reúne as figuras de maior dimensão referidas ao longo do relatório.

A. Matriz de Correlação das Features Escolhidas

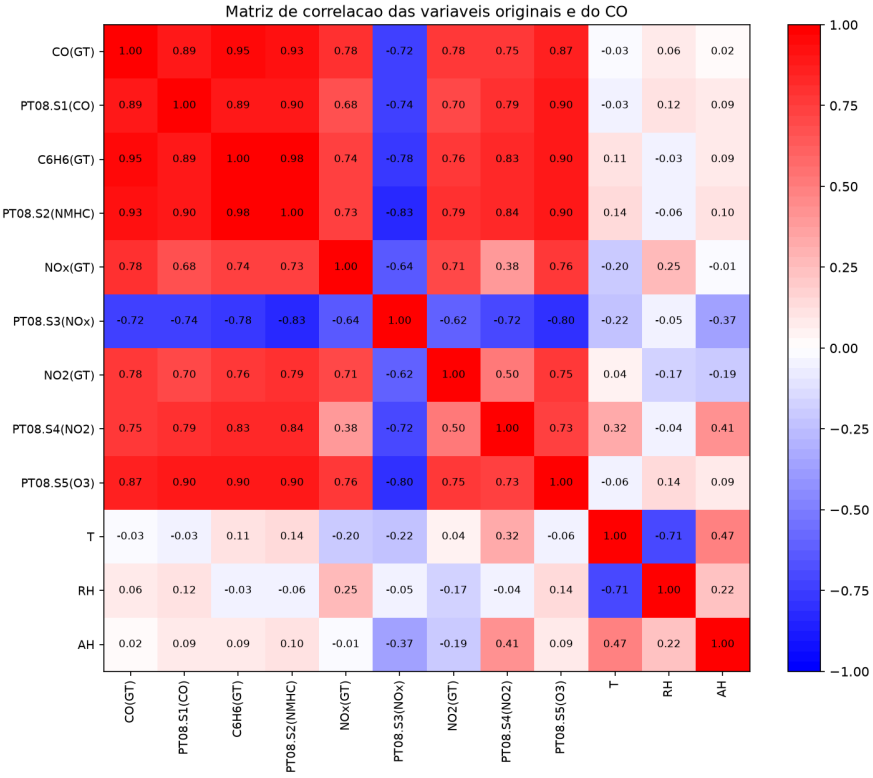


Figura 9. Matriz de correlação das features escolhidas e do CO (treino).

B. Distribuição das Variáveis Originais (1/2)

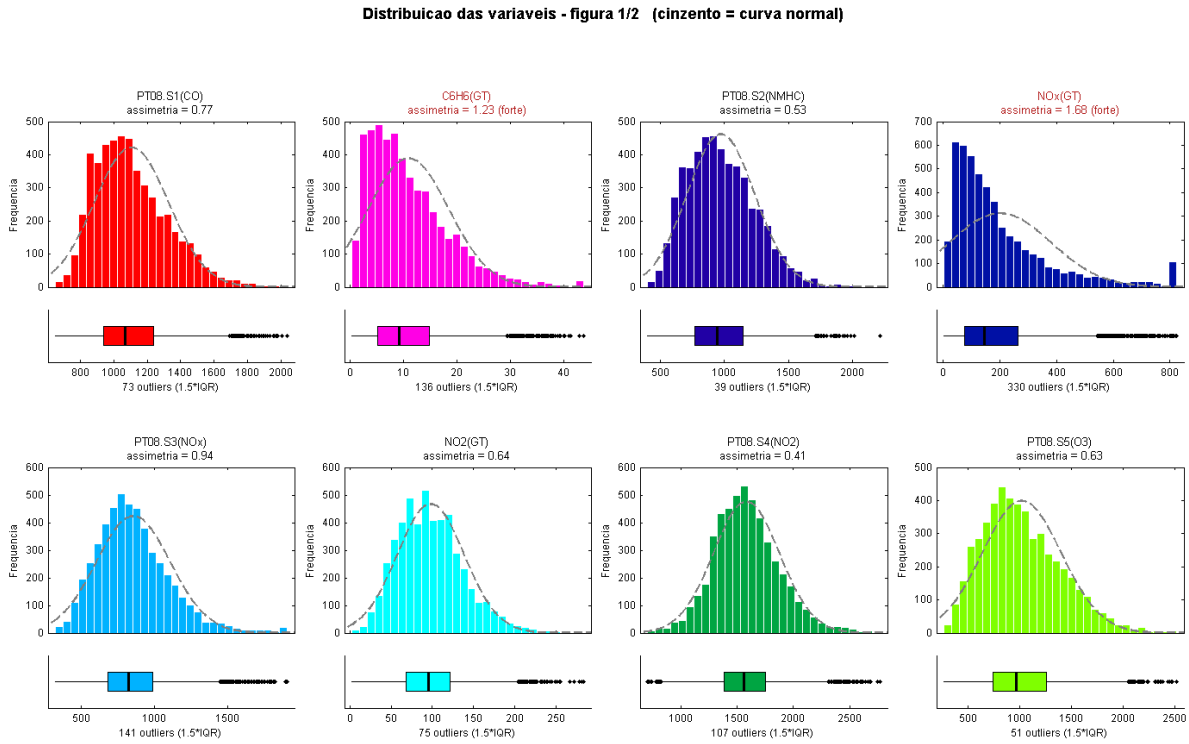


Figura 10. Distribuição das variáveis originais (1/2), no treino e nas unidades reais.

C. Distribuição das Variáveis Originais e do Target (2/2)

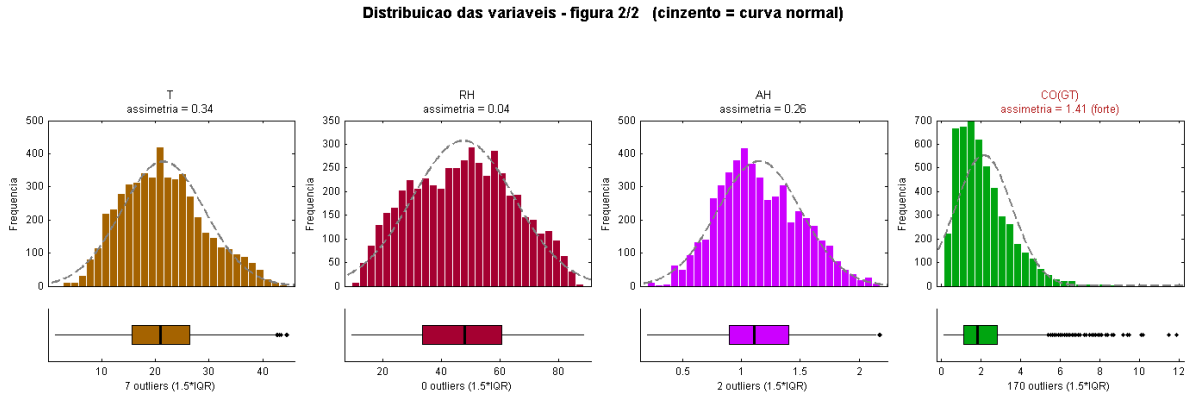


Figura 11. Distribuição das variáveis originais e do target (2/2).

D. Histogramas Antes e Depois da Limpeza

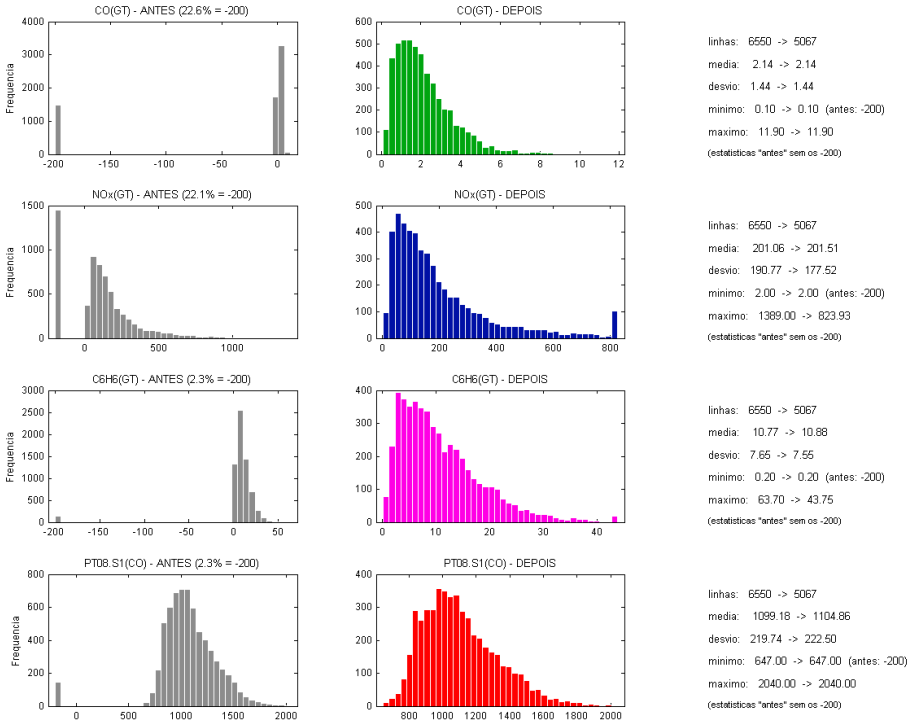


Figura 12. Histogramas antes (com os -200) e depois da limpeza, e estatísticas dos dois lados (treino).

E. Variáveis Mais Correlacionadas com o CO(GT)

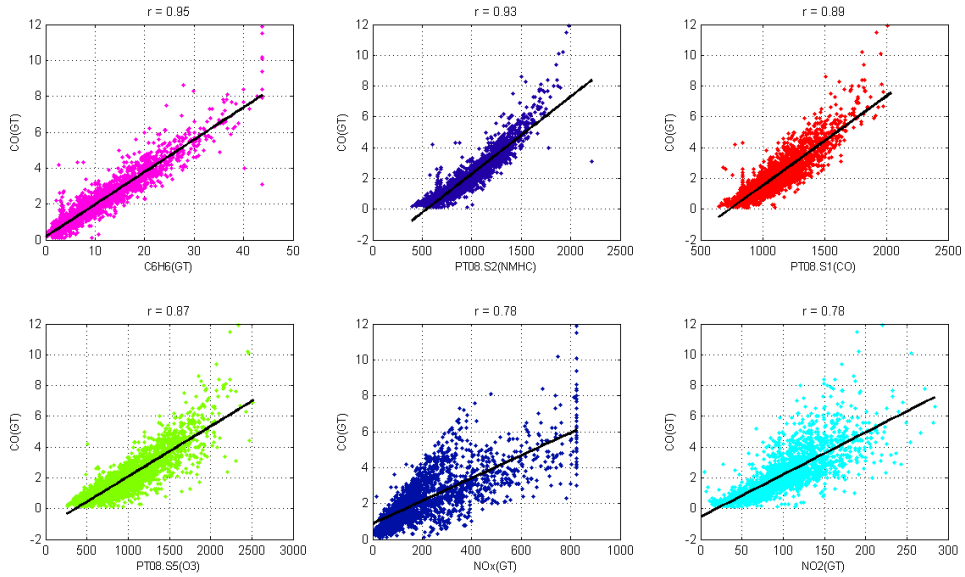


Figura 13. As seis variáveis mais correlacionadas com o CO(GT), com a reta de mínimos quadrados.

REFERÊNCIAS

[1] S. Vito, "Air Quality," UCI Machine Learning Repository, 2008. [Online]. Available: https://archive.ics.uci.edu/dataset/360/air+quality

[2] S. De Vito, E. Massera, M. Piga, L. Martinotto, and G. Di Francia, "On field calibration of an electronic nose for benzene estimation in an urban pollution monitoring scenario," *Sensors and Actuators B: Chemical*, vol. 129, no. 2, pp. 750–757, 2008.